

|                                      |                                         |
|--------------------------------------|-----------------------------------------|
| Bioinformática                       | Nombres: _____                          |
| Segundo periodo de 2026              |                                         |
| Primer parcial                       | Grupo: _____                            |
| Fecha:Jueves 3 de septiembre de 2026 |                                         |
| Tiempo: Una semana para su entrega   | Profesor: <i>Juan Sebastián Malagón</i> |

Este examen contiene el planteamiento del problema general que el grupo desarrollará a lo largo de los tres parciales del semestre. Tenga presente que cualquier intento de fraude será motivo de anulación del parcial.

## 1. Introducción - Contexto

Ustedes son un equipo de investigadores contratados por una empresa de biotecnología marina interesada en enzimas estables a alta presión, con potencial aplicación en procesamiento de alimentos por alta presión (HPP) y en procesos industriales que ocurren en condiciones extremas. Su equipo participó en una expedición oceanográfica en aguas profundas del mar Caribe colombiano, en la región de Malpelo, recolectando muestras de sedimento y agua a gran profundidad. A partir de una de estas muestras lograron aislar una cepa bacteriana adaptada a estas condiciones. La empresa les ha entregado los datos de secuenciación de esta cepa y requiere que confirmen su identidad taxonómica antes de continuar con la evaluación de su potencial biotecnológico.



Figura 1: Isla de Malpelo

## 2. Contenido del parcial

*Material proporcionado en la carpeta “Data”:*

- **Archivo de lecturas brutas (.FASTQ):** Un archivo en formato FASTQ que contiene las lecturas de secuenciación de alto rendimiento (*Next-Generation Sequencing*, NGS) obtenidas directamente a partir del ADN genómico purificado del aislamiento microbiano.
- **Base de datos de secuencias de referencia (.fasta:)** Un conjunto de genes candidatos y secuencias de referencia, seleccionado para la identificación taxonómica del organismo aislado

## 3. Instrucciones y Puntos a Desarrollar

A continuación se presentan las fases metodológicas que cada grupo deberá ejecutar sobre los datos proporcionados para resolver el caso de estudio:

1. **Evaluación de calidad inicial:** Ejecutar la herramienta **FastQC** sobre el archivo de lecturas crudas (.FASTQ) entregado en la carpeta **Data**. Deberán generar el reporte HTML correspondiente e inspeccionar las métricas principales (calidad por base Phred, contenido de GC, presencia de adaptadores y secuencias duplicadas).
2. **Preprocesamiento y limpieza (*Trimming*):** Aplicar herramientas de procesamiento para remover adaptadores de secuenciación y filtrar/recortar bases de baja calidad (según criterio del equipo). **\*\*Justificar\*\*** técnicamente los parámetros seleccionados en función de los hallazgos del primer reporte de calidad. Para ejecutar esta tarea correctamente, se recomienda consultar la documentación oficial de Trimmomatic: <http://www.usadellab.org/cms/?page=trimmomatic>.
3. **Evaluación de calidad posterior a la limpieza:** Ejecutar nuevamente **FastQC** sobre el conjunto de lecturas procesadas y generar el reporte final. El grupo deberá presentar un análisis comparativo entre los reportes del estado inicial y el posterior a la limpieza (el uso de **MultiQC** para consolidar ambos estados es altamente recomendado).
4. **Conversión de formato FASTQ a FASTA:** Una vez finalizados los procesos de filtrado y recorte de calidad, la siguiente fase consiste en convertir las secuencias procesadas a un formato más versátil. Para ello, deberá transformar todos sus archivos FASTQ limpios al formato FASTA. Para realizar esta operación de manera eficiente, debe utilizar el kit de herramientas SeqKit. Específicamente, debe ejecutar el comando `fq2fa`. (Utilice el siguiente comando: `seqkit fq2fa [fastq file] -o [fasta file]`)
5. **Construcción de la base de datos local BLAST:** La siguiente fase del proyecto consiste en preparar la infraestructura necesaria para la identificación taxonómica. A partir de sus lecturas limpias, ya convertidas a formato FASTA, construyan su propia base de datos local de BLAST `makeblastdb`. Puede usar como material de apoyo el siguiente recurso: <https://www.ncbi.nlm.nih.gov/books/NBK569841/>

6. **Búsqueda BLAST contra el pool de genes:** Usando como consulta (query) el pool de genes marcadores, ejecutar BLAST contra la base de datos construida por su grupo, con el fin de determinar la identidad taxonómica de su organismo. Con base en los parámetros del alineamiento obtenido (porcentaje de identidad, cobertura de la alineación, *E-value* y puntaje de bit):

- Determinar la identidad taxonómica más probable de la cepa aislada.
- Justificar técnicamente la elección del organismo candidato analizando la solidez de los estadísticos del BLAST.