Bioinformática
Segundo periodo de 2026
Segundo parcial
Fecha: Jueves 22 de octubre de 2026
Tiempo: Una semana para su entrega

Nombres: _____

Grupo: _____

Profesor: *Juan Sebastián Malagón*

Este examen contiene el planteamiento del problema general que el grupo desarrollará a lo largo de los tres parciales del semestre. Tenga presente que cualquier intento de fraude será motivo de anulación del parcial. **Nota de infraestructura:** Dado el entorno compartido de cómputo, es de carácter obligatorio configurar todas las herramientas a un máximo estricto de **2 hilos de procesamiento** (`-t 2`, `-cpus 2` o `-threads 2`).

1. Introducción - Contexto

En el parcial anterior se confirmó, a partir de datos genómicos, la identidad del microorganismo psicrófilo polar y oxidante de hidrógeno aislado en los glaciares y suelos periglaciares del Parque Nacional Natural El Cocuy (*Polaromonas hydrogenivorans*). Una empresa biotecnológica aliada tiene un alto interés en la explotación comercial de la producción de **enzimas activas en frío** (*cold-active enzymes*) e **hidrogenasas**, biocatalizadores de alto valor para aplicaciones en detergentes, alimentos y biorremediación a bajas temperaturas.

No obstante, antes de escalar la producción en biorreactor, la compañía requiere evaluar **alternativas industriales de microorganismos semejantes** pertenecientes al mismo linaje evolutivo que coexistan en el ecosistema o nichos periglaciares afines, y que presenten eficiencias catalíticas iguales o superiores en condiciones de frío extremo. Para este análisis comparativo, el centro de secuenciación entregó las lecturas crudas de un nuevo aislado del ecosistema y una colección ambiental de secuencias homólogas.

Como marcador molecular de alta resolución utilizaremos el gen ***gyrB***, que codifica para la subunidad B de la ADN girasa (topoisomerasa tipo II, término ontológico **GO:0003918**). Este gen es una enzima esencial universal de copia única en bacterias que introduce superenrollamiento negativo en el ADN. Se selecciona *gyrB* debido a que presenta una tasa de sustitución nucleotídica significativamente mayor que el clásico 16S ARNr, confiriendo un poder de resolución taxonómica superior para discriminar especies crípticas y delinear linajes filogenéticos estrechamente emparentados dentro de la misma familia y género.



Figura 1: Parque Nacional Natural El Cocuy

2. Contenido del parcial

Material proporcionado en la carpeta "**data**":

- **Lecturas pareadas (`.fastq`):** Archivos crudos Illumina (`reads_R1.fastq` y `reads_R2.fastq`).
- **Colección de secuencias (`.fasta`):** Archivo `coleccion_gyrB.fasta` con secuencias homólogas y variantes del entorno.

3. Instrucciones y Fases a Desarrollar

Cada grupo deberá ejecutar de forma rigurosa las siguientes fases metodológicas (empleando estrictamente un **máximo de 2 hilos** en cada comando: `-t 2`, `-cpus 2` o `-threads 2`):

1. **Preprocesamiento y Control de Calidad:** Evaluar la calidad de las lecturas (`reads_R1.fastq` y `reads_R2.fastq`) ejecutando `FastQC` (`-t 2`) y consolidando los reportes con `MultiQC`. Si se detectan adaptadores o baja calidad Phred en los extremos 3', depurar con `Trimmomatic` (estrictamente 2 hilos: `-threads 2`) ajustando parámetros (`ILLUMINACLIP`, `SLIDINGWINDOW:4:20`, `MINLEN`). Reevaluar las lecturas limpias con `MultiQC` para verificar la calidad final.

2. **Ensamblaje *De Novo* y Evaluación Genómica:** Ensamblar el genoma completo del nuevo aislado a partir de las lecturas limpias empleando `SPAdes` en modo aislamientos bacterianos (`spades.py -isolate -t 2 -m 3`). Evaluar la contigüidad del ensamblaje con `QUAST` (`quast.py -t 2`, reportando métricas de N50, longitud total acumulada, cantidad de contigs y porcentaje de GC). Asimismo, cuantificar la completitud y redundancia genómica ejecutando `BUSCO` (`-cpu 2`) con el linaje taxonómico bacteriano correspondiente.

3. **Anotación Estructural, Funcional y Extracción del Marcador *gyrB*:** Realizar la anotación estructural de los contigs resultantes mediante `Prokka` (`prokka -cpus 2`) para obtener los archivos de proteínas (`*.faa`) y nucleótidos (`*.ffn`). Posteriormente, ejecutar la anotación funcional local con `eggNOG-mapper` (`emapper.py -cpu 2 -dmnd_algo ctg -sensmode default -dmnd_iterate no`) sobre las proteínas generadas. Localizar en la tabla de anotaciones el gen ***gyrB*** mediante su asignación funcional ontológica (**GO:0003918**) y recuperar su identificador de locus tag. Utilizar `seqkit grep` para extraer la secuencia nucleotídica completa de *gyrB* desde el archivo `*.ffn`.

4. **Genómica Comparativa y Detección de Organismos Fuera de Distribución (OFDs):** Incorporar la secuencia de nucleótidos de *gyrB* extraída de su aislado en el archivo `coleccion_gyrB.fasta`. Ejecutar un alineamiento múltiple masivo empleando `MUSCLE` para alinear el conjunto completo. Calcular la matriz de distancias de Hamming sobre el alineamiento y realizar un Análisis de Coordenadas Principales (**PCoA**). Generar el gráfico de dispersión bidimensional (PC1 vs PC2) señalando la varianza explicada e identificando los **OFDs** (*Organismos Fuera de la Distribución*, taxones anómalos o alejados del clúster). Proceder a eliminar los OFDs para dejar la colección limpia.

5. **Señales Evolutivas y Reconstrucción Filogenética:** Con el alineamiento depurado y libre de OFDs, inferir el árbol filogenético empleando `BioPython` bajo el modelo de distancia de **Jukes-Cantor** y el método de **Neighbor-Joining** (utilizando el módulo `DistanceTreeConstructor` mediante el algoritmo `nj()`). Generar y graficar el árbol filogenético final con soporte de ramas, demarcando con claridad la ubicación de su aislado problema y la posición de sus taxones hermanos.

6. **Presentación Oral y Sustentación Científica (15 minutos):** Cada grupo dispondrá de un espacio estricto de **15 minutos** para presentar los resultados de su parcial. La sustentación deberá contemplar:
   - Explicación clara del flujo bioinformático ejecutado y justificación de las decisiones metodológicas tomadas en cada fase.
   - Presentación de los organismos evolutivamente más cercanos identificados en la filogenia y su postulación como alternativas para bioprospección industrial.
   - Justificación rigurosa basada en **literatura científica indexada** que contraste y confirme si las especies hermanas propuestas efectivamente poseen evidencia experimental de producir hidrogenasas o enzimas activas en frío requeridas para detergentes, alimentos o biorremediación a bajas temperaturas.